

**UNIVERSIDAD LATINA DE PANAMÁ
SEDE CENTRAL**

FACULTAD DE INGENIERÍA

**Licenciatura en Ingeniería mecatrónica
Diseño mecatrónico**

Título de su investigación

**“ANÁLISIS DEL CONSUMO FOTOVOLTAICO RESIDENCIAL Y
COMERCIAL MEDIANTE MODELOS DE APRENDIZAJE AUTOMÁTICO EN
LA CIUDAD DE PANAMÁ 2020”**

PARTICIPANTE:

Elida Domínguez

7-708-1272

FACILITADOR:

Pablo González Robles

CIUDAD DE PANAMÁ, PANAMÁ

2020

Introducción

El crecimiento del mercado eléctrico en Panamá, es decir, todos aquellos consumidores que producen y consumen electricidad, juegan un papel importante en la llamada transición energética y sus principales impulsores: Descarbonización, descentralización y digitalización. Descarbonización, mediante la generación de energía renovable, especialmente a partir de sistemas fotovoltaicos. La descentralización, mediante el consumo de electricidad autoproducida y la reducción de aquella que es importada de la red. Además, en la digitalización de los sistemas energéticos, descrita como la aplicación de tecnologías de la información y comunicaciones, los métodos de análisis avanzados, como el aprendizaje automático, permiten explotar grandes cantidades de datos con el objetivo de mejorar la gestión energética. Pronosticar el consumo de electricidad de un cliente es una tarea bastante compleja debido al uso irregular de los aparatos eléctricos. De esta manera, los pronósticos confiables son requeridos para optimizar el consumo de electricidad y su respectivo costo. En ese sentido, surge la idea y necesidad de explorar la aplicación práctica de métodos de aprendizaje automático. El objetivo de la investigación es desarrollar un análisis comparativo del consumo fotovoltaico de residencias y comercios con instalaciones fotovoltaicas en la ciudad de Panamá en el año 2020, teniendo en cuenta la aplicación de inteligencia artificial con el fin de estudiar su comportamiento dentro de la red eléctrica para pronosticar el consumo de electricidad a corto plazo de un cliente residencial y comercial en ciudad de Panamá.

Contenido

Introducción	ii
1. El problema de investigación	1
1.1. Antecedentes	2
1.2. Justificación	6
1.3. Preguntas de investigación	8
1.4. Objetivos generales	9
1.5. Objetivos específicos	9
1.6. Hipótesis	9
2. Marco teórico y conceptual	9
2.1. Consumo fotovoltaico	9
2.1.1. Definición de consumo fotovoltaico	10
2.1.2. Tipos de tarifas aplicadas en Panamá	10
2.1.3. Modelo de aprendizaje automático- árbol de decisión	13
2.1.4. Herramientas para el análisis de datos	15
3. Metodología de investigación	17
3.1. Tipo de investigación	17
3.2. Objetos de la investigación	17
3.3. Tratamiento de la información	18
3.4. Instrumentos	19
3.5. Limitaciones y delimitaciones	19
3.6. Proyecciones	20
Bibliografía	21

1. El problema de investigación

El problema de predicción de energía solar y de la obtención del consumo energético se puede formular como sigue: Dado una series de tiempo de datos meteorológicos y de consumos energéticos históricos en la forma $(x_1; x_2; x_n)$, donde n representa el número de parámetros meteorológicos y de consumo energético. Predecir energía solar fotovoltaica diaria y, un enfoque convencional es definir un función de mapeo entre los datos meteorológicos históricos y el futuro energía solar fotovoltaica. Numerosos estudios de investigación han introducido algoritmos ML como modelos de previsión en diferentes aplicaciones relacionadas con el campo de energía renovable. Varias metodologías de aprendizaje automático, como la máquina de vectores de soporte (SVM), la memoria a corto plazo a largo plazo (LSTM) y vecino más cercano (K-NN), se han aplicado para predecir irradiancia solar, que puede considerarse como el primer paso hacia la energía solar y previsión de energía fotovoltaica. Básicamente, toda la investigación que exploramos confirmó que la diversidad es un procedimiento esencial y fundamental para un conjunto de poderosos modelos. Además, se encontró que la mayoría de los estudios basados en conjuntos utilizaron los métodos convencionales de ML por conjuntos, y generalización para aplicar la diversidad, entrenar los mismos modelos de aprendizaje automático y agregar los resultados en un modelo. Sin embargo, este estudio incorpora la predicción resultante de modelos ML y la predicción resultado de la estadística modelo, que no puede ser logrado por el modelo convencional en modelos de ML de conjunto. Además, la investigación que agrega modelos de ML y modelos estadísticos en el pronóstico de energía solar fotovoltaica no

es existente. Por tanto, este estudio podría considerarse uno de los primeros en energía solar en Panamá incluyendo la previsión de potencia (consumo fotovoltaico) que aporta un valor a este campo de investigación.

1.1. Antecedentes

Un modelo de árbol de regresión potenciado por gradiente (GBRT) fue realizado por Persson para predecir la generación de energía solar en varios sitios en un horizonte de pronóstico de uno a seis horas por delante. El modelo GBRT fue diseñado principalmente para clasificación; sin embargo, se ha extendido a la regresión. Además, GBRT es un modelo ML que combina la salida de muchos pequeños árboles de regresión de tamaño fijo para generar mejores resultados. A diferencia del método convencional de series de tiempo, el modelo propuesto no tiene procedimiento de actualización o versión recursiva como nuevas observaciones llegan, que añaden una limitación considerable a su propuesta modelo. Los autores propusieron una contracción mínima absoluta y modelo de pronóstico basado en el operador de selección (LASSO) para generación de energía. El modelo basado en LASSO ayuda en la selección de variables minimizando los pesos de las variables menos importantes y maximizando la escasez del vector de coeficientes general. Ellos compararon la energía solar predicha a partir de su algoritmo propuesto con dos esquemas representativos, SVM y un método basado en series de tiempo conocido como método TLLE. Los resultados mostraron que el algoritmo basado en LASSO logró pronósticos de energía solar más precisos que el esquema representativo que utilizan menos conjuntos de datos de entrenamiento. Como complemento al algoritmo propuesto por Tang, los autores de LASSO integrado con LSTM como modelo de previsión de

energía solar predicción de intensidad. Su modelo propuesto logró un mejor rendimiento en la predicción de la intensidad solar a corto plazo en lugar de la predicción a largo plazo. Además, la previsión de energía de plantas de energía solar utilizando, Auto Encoder (AE) y la red neuronal LSTM fue desarrollada. Utilizaron el lado de codificación del AE para realizar las funciones más efectivas para el aprendizaje y lo conectaron a la red LSTM. En consecuencia, el LSTM utiliza los datos de codificación aprendidos como entrada para predecir la generación de energía solar de una planta fotovoltaica. El modelo mostró resultados poderosos en comparación con perceptrones multicapa (MLP), LSTM, redes de creencias profundas y AE. Diferente de, los autores en combinaron el EA con LSTM aumentado el modelo de previsión de memoria a corto plazo (A-LSTM). El algoritmo se probó en diferentes conjuntos de datos y funcionó bien en conjuntos de datos de series de tiempo. Se desarrolló un modelo basado en LSTM para predecir la energía fotovoltaica utilizando un conjunto de datos limitado. Aunque el modelo LSTM predijo resultados precisos, se demostró que aumentar la cantidad de datos y funciones mejorará el rendimiento del Modelo LSTM. Wang y col. propuso un PV a corto plazo basado en GRU algoritmo de pronóstico de energía. El modelo GRU se utiliza para reducir el largo tiempo de entrenamiento en comparación con el modelo LSTM, así como mejorar la precisión de la salida. Llegaron a la conclusión de que GRU superó los modelos ML tradicionales como SVM, auto regresivo integrado modelo de media móvil (ARIMA), LSTM y red neuronal de retropropagación. Los autores encuestaron modelos de AA de última generación utilizados en diferentes sistemas de energía renovable. Además, identificaron y clasificaron muchos modelos ML aplicados en diferentes aplicaciones en aplicaciones energéticas y exploró diversas investigaciones en diferentes sistemas

energéticos. Demostró una comparación completa de varios métodos que se utilizan con fines de predicción. Exploraron seis métodos diferentes: Red neuronal (NN), SVM, KNN, regresión lineal múltiple (MLR) y dos persistentes métodos. Los resultados mostraron que el conjunto de NN es el más prometedor método preciso en comparación con otros métodos de predicción. Los enfoques estadísticos no han llamado la atención de investigadores tanto como modelos ML, especialmente en energía solar fotovoltaica previsión. Como se mencionó anteriormente, Makridakis, ilustró que el método Theta fue el estadístico más preciso y simple método que funcionó parcialmente bien en M3 Competition. Los autores clasificaron los métodos de conjunto en dos categorías: previsión de conjuntos competitiva y cooperativa previsión de conjuntos. El aprendizaje conjunto es un modelo prometedor que ha atraído mucha atención en los últimos años. Ahmed y col. propusieron tres enfoques conjuntos diferentes para predecir la generación de energía solar diaria a saber: (a) lineal, (b) distribución normal, y (c) distribución normal con características adicionales.

Llegaron a la conclusión de que todos los métodos de conjunto cuando se combinaron mostraron un mejor rendimiento que el individual. Modelos ML. Gigoni y col. comparó varios pronósticos de AA metodologías, por ejemplo, K-NN, soporte de regresión vectorial (SVR) y bosque aleatorio cuantílico y evaluar su precisión de predicción en aplicación de energía solar fotovoltaica. Los resultados experimentales mostraron que la agregación de la salida de modelos de predicción única superó todos los modelos de aprendizaje ML explorados en su investigación bajo cualquier condición climática. Feng y col. agrupó los datos meteorológicos en enfoque basado en similitudes por horas y utilizó esos datos agrupados para entrenar un modelo híbrido ML de dos capas para

poder predecir una irradiancia solar con una hora de antelación. Sus resultados mostraron que el modelo híbrido funcionó mejor que cualquier modelo de AA único utilizado en el modelo híbrido, otro estudio de Kopinska ilustrado en enfoques estáticos y dinámicos para combinar la predicción de energía solar de NN. Su experimento mostró abrumadores resultados para los enfoques de conjunto en comparación con ensacado, refuerzo, bosque aleatorio y cuatro modelos de predicción única (NN, SVM, KNN y un modelo de persistencia). Se pueden encontrar investigaciones limitadas en modelos estadísticos de conjuntos para un rendimiento superior y exactitud. Los autores de exploraron ocho técnicas de conjunto combinar los resultados de los seis mejores modelos de cada familia de modelos estadísticos: SARIMA (36 modelos), ETS (30 modelos), MLP (1 modelo), descomposición STL (2 modelos), TBARS (72 modelos) y el modelo Theta (1 modelo). Aunque el aprendizaje en conjunto mostró alto rendimiento y resultados precisos en muchos papeles, los resultados mostraron una mejora marginal del mejor modelo. La razón es que los modelos probados resultaron en errores correlacionados. Esto nos llevó a enfatizar que la diversidad es la clave hacia una mejora importante de los métodos de conjunto. Los autores presentaron un enfoque basado en grupos aplicado a la radiación solar global. Su enfoque luego predice la radiación solar global horizontal utilizando una combinación de dos modelos MI: SVM y ANN. Los resultados mostraron una mayor precisión de predicción. En comparación con las ANN y SVM convencionales. En resumen, exploramos muchas investigaciones en el pronóstico de energía solar que combina modelos ML para mejorar la precisión de la predicción.

1.2. Justificación

En mención al proyecto ejecutado por Emil Isaksson y Mikael Karpe Conde en el 2018 para el pronóstico de energía solar con aprendizajes automáticos y diversas técnicas tenemos los siguientes datos: El cambio global hacia las fuentes de energía renovable ha impulsado el desarrollo de paneles fotovoltaicos, por ejemplo los costos de producción de electricidad a partir de paneles fotovoltaicos se han reducido significativamente al tiempo que aumentan la eficiencia de conversión de energía. Más específicamente el costo nivelado de la electricidad de los paneles fotovoltaicos a gran escala ha disminuido en un 73% entre los años 2010 y 2017.

(Isaksson, E., 2018), (Karpe Conde, M, 2018).

Javier Huertas Tato del 2017 al 2018 y gracias a su investigación realizada con respecto a la predicción de radiación solar a partir de modelos físicos de aprendizaje automático se obtuvieron los siguientes resultados en España las energías renovables representan un 46% de la potencia instalada y en el 2017 supuso un 33.7% de la producción total de energía durante el año.

Cabe destacar que Uruguay en su análisis de relevamiento de las estrategias de pronóstico del recurso solar y diagnóstico de las alternativas nacionales, realizado por el laboratorio de energía solar del instituto de mecánica de fluidos e ingeniería ambiental, indica que actualmente cuentan con plantas operativas de mediano porte que se encuentran inyectando energía a la red y que para finales 2017 presentaron 280 megawatts de capacidad instalada. (Tato, J. H, 2019).

Por ende en Panamá en un artículo publicado por La Prensa Panamá el 29 de septiembre de 2019, indica que la energía solar es la esperanza panameña, la energía solar es inagotable, la más limpia, y la más barata, y que Panamá ya está tomando medidas conforme a ella. También Panamá en su plan energético nacional 2015-2050 pretende que la generación de energía eléctrica en el año 2050 sea en un 70% proveniente de fuentes renovables sobre todo solar y eólica, que además de ser limpia produce ahorros. Hasta la fecha la autoridad Nacional de los servicios públicos (ASEP, 2020) ha otorgado 15 licencias definitivas fotovoltaicas y 24 licencias provisionales fotovoltaicas para empresas, para instalar plantas que generan energía solar en el territorio panameño el marco regulatorio vigente panameño que permita la instalación de hasta 15 kilowatts por sitio de paneles solares. Los clientes de autoconsumo aportan alrededor de 15 megawatts, casi el 1% de la demanda total de Panamá.

Por tal razón la tecnología de la Inteligencia artificial mejora la confiabilidad en las energías renovables, esta confianza se ve mermada en gran parte variable en el rendimiento de las energías renovables ocasionado por las condiciones climáticas y que con esta tecnología se ofrece una gran mejora en su predicción. De esta manera podemos preparar los sistemas para que trabajen en las mejores condiciones y situaciones posibles para sacar los mejor de estos a grandes rasgos.

Mejoras que vendrán con esta tecnología: Centros de control inteligente y centralizado, seguridad y confianzas mejoradas, integración mejorada de redes eléctricas, almacenamiento inteligente de energía.

Con toda esta información podemos realizar los diferentes tipos de predicciones matemáticas para obtener los resultados en cuanto al comportamiento energético de un área específica o de un área en general. Es de ayuda para aquellas empresas de distribución de energía que deseen realizar sus predicciones futuras en cuanto al consumo de sus clientes en un período de tiempo.

El aporte de la predicción de la energía fotovoltaica es un área de investigación importante que utiliza diferentes técnicas de predicción que mitigan los efectos de la incertidumbre de la generación fotovoltaica. El nivel de penetración cada vez más alto de la generación fotovoltaica (PV) surge en el concepto de redes inteligentes y micro redes . La fuente solar es de naturaleza irregular como resultado, la energía fotovoltaica es intermitente y depende en gran medida de la irradiancia, nivel de temperatura y otros parámetros atmosféricos. Los datos obtenidos por medio de esta investigación estarían aportando al marco regulatorio de las empresas de distribución de energía eléctrica, apuntando a un mejor registro y manejo de esta información dentro de la organización. (Studio, C, 2018).

1.3. Preguntas de investigación

¿De qué manera el análisis del consumo fotovoltaico implementando modelos de machine learning aportará al comportamiento de la red eléctrica de distribución en la ciudad de Panamá durante el periodo 2020-2021?.

1.4. Objetivos generales

Desarrollar un análisis comparativo del consumo fotovoltaico de residencias y comercios con instalaciones fotovoltaicas en la ciudad de Panamá teniendo en cuenta la aplicación de inteligencia artificial con el fin de estudiar su comportamiento dentro de la red eléctrica.

1.5. Objetivos específicos

- Estimar cantidad de residencias y comercios con instalaciones fotovoltaicas.
- Clasificar el consumo energético de instalaciones fotovoltaicas.
- Proponer un modelo de inteligencia artificial para el desarrollo del análisis comparativo del consumo fotovoltaico de residencias y comercios.

1.6. Hipótesis

El análisis de consumo fotovoltaico mediante la aplicación de inteligencia artificial pronosticará el comportamiento de las tarifas residenciales y comerciales dentro del sistema de distribución de energía eléctrica en la ciudad de Panamá.

2. Marco teórico y conceptual

2.1. Consumo fotovoltaico

Para el análisis y modelado de un sistema fotovoltaico se han considerado varios parámetros que permiten caracterizar este tipo de sistemas. Estos parámetros están relacionados, por una parte, con la estimación de la energía que producen este tipo de instalaciones y, por otra, con la evaluación del funcionamiento de estos

sistemas. En esta sección se describen las expresiones y conceptos para estimar estos parámetros y los distintos modelos utilizados.

2.1.1. Definición de consumo fotovoltaico

Se define como la parte de energía producida por el sistema fotovoltaico que es consumida directamente en la vivienda o donde está la instalación, respecto a la producción total del sistema fotovoltaico. (Gilardon, A. C. A, 2019) adicional es considerada también la parte de la energía producida directamente de un local comercial ya que forma parte del total del sistema fotovoltaico. En conclusión todo equipo tecnológico que aporte a la producción de energía eléctrica de manera individual.

2.1.2. Tipos de tarifas aplicadas en Panamá

Ámbito de aplicación

Conforme a lo establecido en la Resolución JD-5863 del 17 de febrero de 2006, sus modificaciones y cumpliendo con todas las disposiciones legales y regulatorias de la Autoridad Nacional de los Servicios Públicos, se presentan los cargos tarifarios que serán aplicados a los clientes regulados, así como los cargos por uso de las redes de distribución eléctrica que estarán vigentes en el periodo del 1° de julio al 31 de diciembre del 2020.

Este Pliego Tarifario contiene la estructura tarifaria aprobada mediante la Resolución AN No.13004-Elec de 12 de diciembre de 2018 para el periodo comprendido del 1 de enero de 2019 al 30 de junio de 2022. Además, fue diseñado siguiendo las metodologías, fórmulas y valores establecidos en el Régimen

Tarifario y de acuerdo con los criterios establecidos en el artículo 97 de la Ley 6 del 3 de febrero de 1997.(Ensa,2020).

Los cargos asociados a la actividad de distribución y comercialización de energía eléctrica, están asignados conforme la resolución AN No.13004-Elec del 12 de diciembre de 2018, que le aprobó el Ingreso Máximo Permitido (IMP) para el periodo julio 2018- junio 2022. (ASEP, 2020).

Como estos cargos se aplicarán a partir del 1 de enero de 2020, se han actualizado con el Índice de Precios al Consumidor (IPC) que corresponde según el Régimen Tarifario vigente.

Los cargos asociados al abastecimiento de energía corresponden a los costos previstos para el segundo semestre del 2020. De acuerdo a lo establecido en el Régimen Tarifario y la Ley 6 de 3 de febrero de 1997, los cargos serán actualizados semestralmente. (ASEP, 2020).

Opciones tarifarias

Toda persona natural o jurídica podrá elegir libremente cualesquiera de las tarifas que se describen más adelante, con las limitaciones establecidas en cada caso y dentro del nivel de tensión que les corresponda.

Clasificación, alta, media y baja tensión

Son clientes en alta tensión aquellos que estén conectados a redes cuya tensión sea de 115 kilovoltios (115 kV). Son clientes en media tensión aquellos que estén conectados a redes cuya tensión sea inferior a 115 kilovoltios y superior a 600 voltios (600 V). Son clientes en baja tensión aquellos que estén conectados a redes cuya tensión sea igual o inferior a 600 voltios.

Tarifa BTD: Tarifa con demanda máxima

Esta tarifa se aplica a cualquier uso de la energía eléctrica de los clientes con una demanda máxima mensual mayor de 15 kilovatios (15 kW), conectados en baja tensión.

Resumen de los Cargos:		
Cargo Fijo	4.87	B/. /cliente/mes
Cargo por Demanda Máxima	15.16	B/. /kW/mes
Cargo por Energía (1eros. 10,000 kWh)	0.15174	B/. /kWh
Cargo por Energía (Siguietes kWh de 10,0001 a 30,000)	0.15559	B/. /kWh
Cargo por Energía (Siguietes kWh de 30,0001 a 50,000)	0.15966	B/. /kWh
Cargo por Energía (Siguietes kWh en exceso de 50,001)	0.16392	B/. /kWh
Composición de los Cargos		
Comercialización		
Cargo Fijo	4.87	B/. /cliente/mes
Cargo por Energía	0.00517	B/. /kWh
Distribución		
Cargo por Demanda Máxima	12.17	B/. /kW/mes
Cargo por Energía	0.00000	B/. /kWh
Pérdida de Distribución		
Cargo por Pérdidas Estándar de Demanda	0.31	B/. /kW/mes
Cargo Pérdidas Estándar de Energía	0.00936	B/. /kWh
Alumbrado Público	0.00111	B/. /kWh
Transmisión		
Demanda Máxima	0.98	B/. /kW/mes
Cargo por Energía	0.01319	B/. /kWh
Pérdida de Transmisión		
Cargo por Energía	-0.00011	B/. /kWh
Generación		
Demanda Máxima	1.70	B/. /kW/mes
Cargo de Potencia Energizada	0.04397	B/. /kWh
Cargo por Energía (1eros. 10,000 kWh)	0.07743	B/. /kWh
Cargo por Energía (Siguietes kWh de 10,0001 a 30,000)	0.08128	B/. /kWh
Cargo por Energía (Siguietes kWh de 30,0001 a 50,000)	0.08535	B/. /kWh
Cargo por Energía (Siguietes kWh en exceso de 50,001)	0.08961	B/. /kWh
Cargo por Abastecimiento de Alumbrado Público	0.00162	B/. /kWh

Fig.1. Pliego Tarifario Segundo Semestre 2020. (2020, Junio 29). Recuperado de Octubre 29, 2020, de <https://www.ensa.com.pa/pliego-tarifario-segundo-semester-2020>.

Tarifas MTD para clientes conectados en media tensión

Los clientes conectados en voltajes mayores que 600 V y menores que 115 kV pueden escoger entre la Tarifa con Demanda Máxima MTD o la Tarifa por Bloque Horario MTH. Para este caso estaremos estudiando la MTD.

<u>Resumen de los Cargos:</u>		
Cargo Fijo	8.73	B/. /cliente/mes
Cargo por Demanda Máxima	12.78	B/. /kW/mes
Cargo por Energía	0.13496	B/. /kWh
<u>Composición de los Cargos</u>		
Comercialización		
Cargo Fijo	8.73	B/. /cliente/mes
Cargo por Energía	0.00388	B/. /kWh
Distribución		
Cargo por Demanda Máxima	9.62	B/. /kW/mes
Cargo por Energía	0.00000	B/. /kWh
Pérdida de Distribución		
Pérdidas Estándar de Demanda	0.24	B/. /kW/mes
Pérdidas Estándar de Energía	0.00697	B/. /kWh
Alumbrado Público	0.00111	B/. /kWh
Transmisión		
Cargo por Demanda Máxima	1.01	B/. /kW/mes
Cargo por Energía	0.00816	B/. /kWh
Pérdida de Transmisión		
Cargo por Energía	-0.00011	B/. /kWh
Generación		
Cargo por Demanda Máxima	1.91	B/. /kW/mes
Cargo por Potencia Energizada	0.03265	B/. /kWh
Cargo por Energía	0.08068	B/. /kWh
Cargo por Abastecimiento de Alumbrado Público	0.00162	B/. /kWh

Fig 2. Pliego Tarifario Segundo Semestre 2020. (2020, Junio 29). Recuperado el 29 de octubre de 2020, de <https://www.ensa.com.pa/pliego-tarifario-segundo-semester-2020>.

2.1.3. Modelo de aprendizaje automático- árbol de decisión

En la actualidad existen sensores digitales, medidores eléctricos de consumo de energía entre otros, se estima que los sensores intercomunicados en los diferentes sectores de la economía brindan un crecimiento anual para gestionar toda la información se requiere desarrollar tecnología para la captura, almacenamiento, análisis y visualización de datos. Las técnicas implican el uso de la estadística, minería de datos, aprendizaje automático, procesamiento de señales,

reconocimiento de patrones, métodos de optimización y métodos de visualización. Una de las principales formas de controlar el consumo energético es a través de la implementación de sistemas de medición avanzada la cual permite capturar los datos para posteriormente ser analizados, a continuación se describen técnicas como potenciales fuentes indispensables para el desarrollo de los aspectos técnicos y económicos de la implementación.

Definición árbol de decisión

Es un método de aprendizaje supervisado no paramétrico que se utiliza para clasificación y regresión . El objetivo es crear un modelo que prediga el valor de una variable objetivo aprendiendo reglas de decisión simples inferidas de las características de los datos. (scikit-learn, 2020).

El Árbol de decisión es un instrumento adecuado que permite tratar los parámetros aleatorios para la solución de problemas de optimización estocástica en el campo de análisis de recursos naturales.

Descripción de la técnica

Un árbol de decisión es una estructura lógica construida a partir de un conjunto de reglas. Las primeras propuestas de utilizar árboles de decisión a partir de conjuntos de datos fueron propuestas en (Hunt et al.1966), (Quinlan, 1979), (Quinlan, 1983) y (Quinlan, 1986).

Gráficamente, este conjunto de reglas se puede representar de la siguiente forma:

If condicion_1 THEN decision_1 ELSE IF condicion_2 THEN decision_2 ELSE IF condicion_3 THEN decision_3... (Gilardon, A. C. A, 2019) , (Cardona Ortín, D. M. S, 2019).

Los árboles de decisión pueden ser representados como un conjunto de ramas y nodos los cuales brindan una solución rápida y comprensible para el interpretador de datos.

Regresión y clasificación

Son una opción atractiva para regresión y clasificación, para respuestas y tratamiento de grandes volúmenes de datos con relaciones complejas y no evidentes entre ellas. Se crean árboles secuenciales cuyos estados cambian con la incorporación de nuevos datos y proporcionan algoritmos de aprendizaje de partículas que hacen que los árboles se creen de manera eficiente.

Et al. "Cultura participativa (Urgarte et al., 2017)".

Aplicaciones de los árboles de decisión

Son usados exitosamente en algunas áreas tales como la clasificación de señales de radar, el reconocimiento de caracteres, la detección remota, diagnóstico médico, sistemas expertos y reconocimiento de voz. Y adicional para construir las predicciones del consumo eléctrico para el estudio y evaluación de las estrategias.(Valencia López, D. 2019).

2.1.4. Herramientas para el análisis de datos

Python

Para este trabajo se toma en consideración la herramienta de Python, para la toma de decisiones del desarrollo del código y puesta en marcha del modelo a crear debido a la gran cantidad de ventajas que la misma ofrece de las cuales se citan las siguientes:

- Es un lenguaje interpretado, rápido y con una sintaxis clara y sencilla.
- Es uno de los lenguajes que más ha crecido en estos últimos años en su uso para la inteligencia artificial.
- Las herramientas Big Data más usadas tienen sus APIs escritas en Python (Apache Spark). Posee un gran abanico de librerías Open Source para el desarrollo de proyectos en inteligencia artificial.
- Además, Python cuenta con una extensa colección de librerías que ayudan en la manipulación de datos para realizar transformaciones y operaciones sobre conjuntos de datos grandes. (Francisco Mendaña, I,2018)

Jupyter Notebook

Jupyter Notebook es una poderosa herramienta de código abierto basada en navegador para el desarrollo interactivo y la presentación de proyectos de ciencia de datos. Cada cuaderno consta de una colección de celdas ejecutables, y cada celda contiene texto formateado con el lenguaje Markdown o código ejecutable (generalmente Python o R). Cuando se ejecuta una 'celda de código', cualquier salida gráfica o de texto (resultados numéricos, figuras o tablas) se presenta dentro del documento inmediatamente debajo de la celda. Una forma popular de comenzar con Jupyter Notebooks es instalar la distribución Anaconda, para la cual hay instaladores gráficos disponibles en los sistemas operativos Windows, macOS y Linux, y adicional creando nuestro ambiente de desarrollo. Después de la instalación, se puede iniciar un servidor Jupyter local utilizando la aplicación Anaconda-Navigator. Para ejecutar un cuaderno Jupyter local específico con Anaconda-Navigator, el usuario puede navegar a la carpeta local apropiada usando la interfaz basada en navegador y hacer clic en el archivo del cuaderno deseado (que se puede identificar con el sufijo *.ipynb*). Seguido de esto podemos desarrollar nuestro código de manera amena y cómoda.

1. Metodología de investigación

3.1. Tipo de investigación

La información presentada a continuación es manejada como una investigación de tipo cuantitativo debido a que se dedica a recoger, procesar y analizar datos cuantitativos o numéricos sobre variables previamente determinadas. Esto ya hace darle una connotación que va más allá de un mero listado de datos organizados como resultado; pues estos datos que se muestran en el informe final, están en total consonancia con las variables que se declararon desde el principio y los resultados obtenidos van a brindar una realidad específica a la que estos están sujetos. (Schwartz, M, 2019). Esta investigación es aplicada ya que no solo requiere alcanzar los niveles previos, sino que también requiere desarrollar una aplicación de la solución al problema de investigación.

3.2. Objetos de la investigación

La disponibilidad de datos de consumos eléctricos para poder hacer un correcto diseño, análisis y evaluación de los sistemas fotovoltaicos, en general, y de los de autoconsumo, en particular, es fundamental. Existen algunas fuentes de datos de este tipo, aunque no siempre con la resolución temporal adecuada de manera que pueda hacerse un análisis detallado del funcionamiento de este tipo de sistemas.

(Gilardón, A. C. A., 2019), (Cardona Ortín, D. M. S, 2019).

Se encuentra dirigido al autoconsumo que presenta cada cliente residencial o comercial y específicamente a su facturación mensual en la cual se ve reflejado el

autoconsumo con cual puede ser estudiado de manera lineal con respecto a sus variables.

3.3. Tratamiento de la información

En este estudio, se describe una metodología experimental para resolver el problema de previsión energética, la cual comprende un proceso de construcción y evaluación de modelos de predicción basados en los métodos árbol de decisiones y series de tiempo. Esta metodología es aplicada al área residencial y comercial, cuyas mediciones históricas de consumo eléctrico en combinación con diversas variables son utilizadas como datos de entrada para entrenar y optimizar los modelos predictivos. Para construir desde cero los modelos propuestos, se propone utilizar un software popular de ciencia de datos: Python.

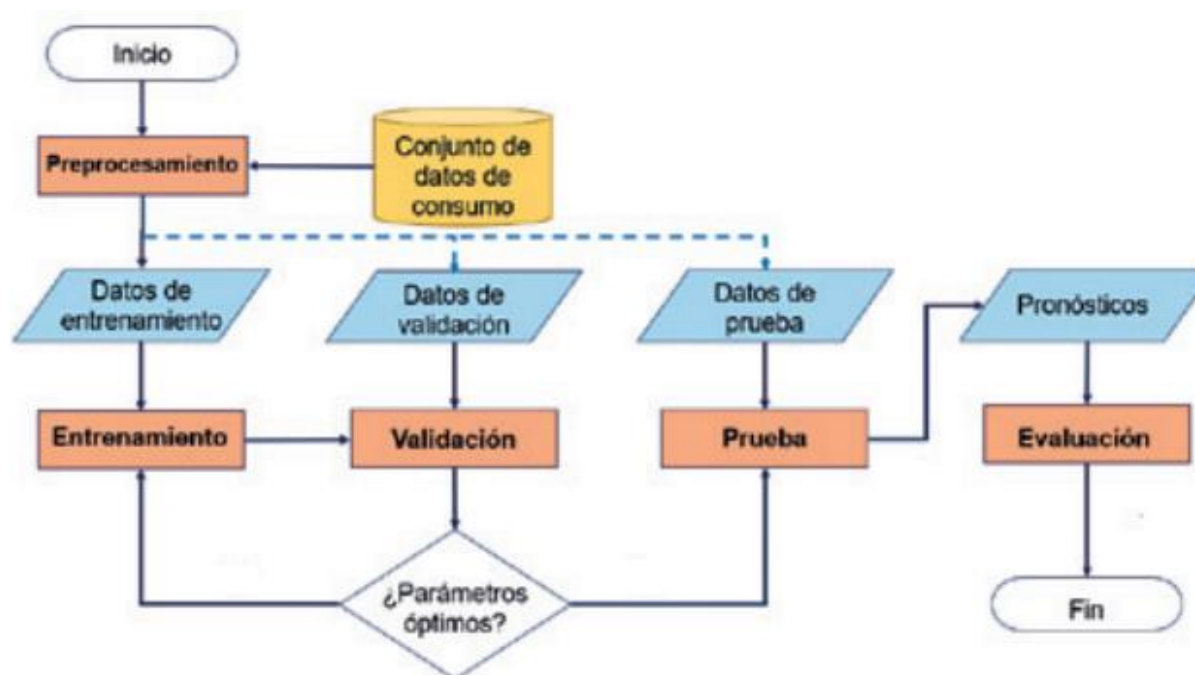


Fig.3 Diagrama de flujo para construir modelos basados en aprendizaje.

3.4. Instrumentos

Para este estudio de investigación se proponen los siguientes software y herramientas:

- **Python**

Lenguaje de programación interpretado, el mismo soporta orientación a objetos este estará siendo evaluado para el procesamiento de información.

- **Kaggle**

La misma nos permite interactuar activamente con conjuntos de datos con miles de tareas, también podemos ayudar a la comunidad resolviendo diversas tareas en conjunto de datos y estas a su vez pueden ser compartidas.

- **Jupyter notebooks**

Es un entorno de trabajo interactivo que soporta más de cuarenta lenguajes de programación como Python, R entre otros, que permite desarrollar código de manera dinámica, a la vez que integra en un mismo documento bloques de código como texto, ecuaciones, gráficas o imágenes

3.5. Limitaciones y delimitaciones

Consideramos las siguientes:

Limitaciones:

- La situación sanitaria actual dada dentro del ámbito donde se realizará el estudio.
- Selección de métodos y modelados de Inteligencia artificial y machine learning para el análisis de datos del proyecto de investigación.

- La obtención de la fuente de datos para el análisis de la información.
- Al momento de realizar el entrenamiento del modelo debe ser guardado progresivamente para que no se dé la pérdida de información.

Delimitaciones:

- El tiempo requerido para la depuración de los datos al momento del inicio del análisis.
- Que la aplicación de los modelos no arrojen el 100% de eficiencia.
- Evaluar ambas herramientas (PYTHON y RSTUDIO) para utilizar la que mayormente se ajuste a los requerimientos.
- Esta investigación solo podrá ser aplicada al sector energético, específicamente para predecir el consumo.

3.6. Proyecciones

Para estudios posteriores dentro de esta temática el análisis inteligente de consumo fotovoltaico puede ser utilizado por entidades gubernamentales como la ASEP (Autoridad de los servicios públicos) para crear o mejorar leyes que regulan al sector energético, también puede ser incorporado en el área de gestión ambiental como análisis que aporten al crecimiento y manejo del medio ambiente, este tipo investigación puede aportar al área de tecnología informática en donde se puedan mejorar las capacidades de los científicos de datos.

Bibliografía

- [1] «Isaksson, E., & Karpe Conde, M. (2018). Solar Power Forecasting with Machine Learning Techniques.» .
- [2] «Tato, J. H. (2019). Machine learning methods for solar irradiance forecast blending and estimation (Doctoral dissertation, Universidad Carlos III de Madrid).» .
- [3] «AN No.16063-Elec de 2020-04-28. (2020, May 18). Recuperado de Octubre 29, 2020, from <https://www.asep.gob.pa/?p=195205>» .
- [4] «Studio, C. (2018, May 24). La energía solar es la esperanza panameña. Recuerado de Octubre 29, 2020, de https://www.prensa.com/locales/energia-solar-esperanza-panamena_0_5036496338.html» .
- [5] «Gilardon, A. C. A. (2019). Modelos para la evaluación y optimización de instalaciones fotovoltaicas de autoconsumo (Doctoral dissertation, Universidad de Málaga).» .
- [6] «Pliego Tarifario Segundo Semestre 2020. (2020, Junio 29). Recuperado de Octubre 29, 2020, de <https://www.ensa.com.pa/pliego-tarifario-segundo-semester-2020>» .
- [7] «AN No.13004-Elec del 12 de diciembre de 2018. (2020, May 18). Recuperado de Octubre 29, 2020, de <https://www.asep.gob.pa/?s=AN+No.13004-Elec+del+12+de+diciembre+de+2018>» .
- [8] «Ley 6 de 3 de febrero de 1997. (2011, Junio 08). Recuperado de Octubre 29, 2020, de <https://www.asep.gob.pa/?s=Ley+6+de+3+de+febrero+de+1997>» .
- [9] «1.10. Decision Trees. (n.d.). Recuperado de October 29, 2020, de <https://scikit-learn.org/stable/modules/tree.html>» .
- [10] «Gilardón, A. C. A., de Cardona Ortín, D. M. S. (2019). TESIS DOCTORAL MODELOS PARA LA EVALUACIÓN Y OPTIMIZACIÓN DE INSTALACIONES FOTOVOLTAICAS DE AUTOCONSUMO. Málaga.» .
- [11] «Ugarte, A. R., Fernández, C. G., McWilliams, J. M. M, 2017. Predicción de precios de energía eléctrica utilizando árboles dinámicos. et al. “Cultura participativa (Ugarte et al., 2017)”» .
- [12] «Valencia López, D. 2019 Programas de Gestión de Demanda Energética en el Sector Industrial. Aplicación de la Analítica para su Diseño e Implementación (Doctoral dissertation, Universidad Nacional de Colombia-Sede Manizales).» .

- [13] «Francisco Mendaña, I. (2018). Predicción de radiación solar a partir de modelos físicos y aprendizaje automático (Bachelor's thesis).» .
- [14] «Project Jupyter. (n.d.). Recuperado de Octubre 30, 2020, de <https://jupyter.org/>».
- [15] «The World's Most Popular Data Science Platform. (n.d.). Recuperado de Octubre 30, 2020, de <https://www.anaconda.com/>».
- [16] «Schwarz, M. (2019). Guía de referencia para la elaboración de una investigación aplicada. Recuperado de <http://repositorio.ulima.edu.pe/handle/ulima/6029>.